

Tradução de Língua Gestual com Visão Computacional e Machine Learning

Revisão do Estado da Arte e Proposta de Implementação

Sensorização e Ambiente

Luís Cunha (pg60280) | Nuno Araújo (pg61218) | Rodrigo Ferreira (pg60392) | Tomás Melo (pg60018)

Contents



1	Contexto e Motivação	4
1.a	Motivação e Âmbito	5
1.b	Disponibilidade de Dados	6
2	Estado da Arte	7
2.a	Técnicas de Captura e Sensorização	8
2.b	MediaPipe — Framework de Sensorização	9
2.c	Modelos para Gestos Estáticos	10
2.d	Modelos para Gestos Dinâmicos	11
3	Proposta de Implementação	12
3.a	Arquitetura Geral do Sistema	13
3.b	Módulo de Gestos Estáticos	14
3.c	Módulo de Gestos Dinâmicos	16
3.d	Síntese das Decisões Técnicas	18
4	Cenários de Aplicação	19
4.a	Contexto Educativo e Gamificação	20
4.b	Saúde e Serviços de Emergência	21

Contents (ii)



4.c	Cidades Inteligentes e Espaços Públicos	22
5	Dimensões Sociais e Éticas	23
5.a	Questões Éticas	24
5.b	Privacidade e RGPD	25
6	Conclusão	26
6.a	Síntese e Trabalho Futuro	27

1 Contexto e Motivação

A barreira de comunicação

A Língua Gestual Portuguesa (LGP) é reconhecida constitucionalmente como a língua da comunidade surda portuguesa.

- **30.000 pessoas** usam a LGP como língua principal
- A grande maioria da população ouvinte **desconhece** a LGP
- Escassez de **intérpretes certificados**
- Barreiras em: saúde, educação, transportes, serviços públicos

Solução proposta: Sistema de tradução automática com visão computacional e Machine Learning, utilizando apenas uma câmara convencional.



Porquê ASL em vez de LGP?

A LGP carece de **datasets públicos anotados** em quantidade suficiente para treinar modelos robustos.

LGP

Recursos muito limitados, sem datasets de grande dimensão publicamente acessíveis

ASL

+87.000 imagens (ASL Alphabet), +2.000 sinais (WLASL), ASL-LEX com 3.000 gestos

As metodologias desenvolvidas para ASL são **transferíveis para LGP** assim que datasets adequados estejam disponíveis.

2 Estado da Arte



Dois grandes grupos de abordagens:

Hardware especializado

Luas com sensores de flexão e acelerómetros — dados precisos mas intrusivos e dispendiosos

Visão computacional

Câmaras RGB convencionais — acessível, não-invasivo, sem hardware especializado

Vantagem dos landmarks 3D:

- Reduz dimensionalidade dos dados
- Invariante a cor de pele
- Facilita interpretação do modelo

MediaPipe — Framework de Sensorização



MediaPipe Hands (Google, open-source):

- Detecção e rastreamento em tempo real de até 2 mãos
- **21 landmarks 3D** por mão → vetor de 63 valores (21×3 coordenadas x, y, z)
- Inferência **on-device**, sem envio de dados para servidores

MediaPipe Holistic (para gestos dinâmicos):

- Combina: pose corporal (33 landmarks) + malha facial (468 pontos) + landmarks das mãos
- Representação completa do signatário em tempo real

Reconhecimento do alfabeto dactilológico — classificação multiclasse por frame

Trabalho	Modelo	Accuracy	Representação
Pugeault & Bowden	Random Forest	57%	Pixels RGB
Pannattee et al.	CNN + Multi-task	72%	Pixels RGB
Buttar et al.	Rede Neuronal Profunda	96%	Landmarks

As **landmarks 3D** permitem obter representações mais compactas e invariantes, alcançando resultados competitivos com menor custo computacional.

Modelos para Gestos Dinâmicos



Reconhecimento de palavras/frases — análise de sequências temporais

Arquiteturas recorrentes são as mais adequadas: **LSTM** e **GRU**

Trabalho	Modelo	Accuracy	Representação
Buttar et al	CNN + LSTM	80%	Landmarks
Srivastava et al.	LSTM	88%	Landmarks
Huang & Chouvatut	ResNet + LSTM	86%	Pixels RGB
Kothadiya et al.	Vision Transformer (ViT)	99%	Pixels RGB

3 Proposta de Implementação



Pipeline completo (5 etapas sequenciais):

1. **Captura** — Câmara RGB convencional captura vídeo em tempo real
2. **Sensorização** — MediaPipe extrai landmarks 3D frame a frame
3. **Classificação** — Módulo estático (MLP) ou dinâmico (LSTM) reconhece o gesto
4. **Pós-processamento** — LLM gera frase gramaticalmente coerente a partir dos sinais reconhecidos
5. **Output** — Texto apresentado e sintetizado em voz localmente

Interface implementada como **aplicação web local**, compatível com webcam, texto e áudio.

Reconhecimento do alfabeto dactilológico ASL — 29 classes

(26 letras + *space*, *delete*, *nothing*)

Dataset

ASL Alphabet Dataset (Kaggle) — >87.000 imagens, 29 classes balanceadas

Pipeline

Imagem → MediaPipe Hands → vetor de 63 valores → MLP

Modelo

Multi Layer Perceptron (MLP), 2-3 camadas densas

Módulo de Gestos Estáticos (ii)



Vantagem

Input reduzido, baixo custo computacional

Literatura reporta accuracies **consistentemente superiores a 90%** com esta abordagem.



Reconhecimento de palavras ASL — 100 classes (WLASL-100)

Dataset

WLASL-100 (100 gestos mais frequentes do Word-Level ASL dataset)

Sensorização

MediaPipe Holistic — mãos + pose + rosto em simultâneo

Modelo

LSTM — captura dependências temporais em sequências de landmarks



Desafio

Vídeos WLASL com qualidade variável → interpolação de landmarks em frames com detecção falhada

Pós-processamento com LLM (on-device):

Sequência reconhecida → LLM local (ex: Phi-3 Mini, Llama 3 8B) → frase gramaticalmente correta

“I WANT WATER” → “I would like some water, please.”



Componente	Gestos Estáticos	Gestos Dinâmicos
Dataset	ASL Alphabet (Kaggle)	WLASL-100
Sensorização	MediaPipe Hands	MediaPipe Holistic
Modelo	MLP	LSTM
Classes	29 (alfabeto ASL)	100 palavras
Output	Letra/caracter	Palavra + LLM → frase

4 Cenários de Aplicação



Aprendizagem interativa por ouvintes

- Feedback imediato sobre a execução de gestos
- Elementos de **gamificação**: pontuações, níveis progressivos, conquistas
- Modelo análogo ao **Duolingo**, adaptado à modalidade gestual
- Dashboard de progresso para professores em contexto de sala de aula

Desafios específicos:

- Variabilidade de hardware escolar (qualidade de webcams, iluminação)
- Necessidade de personalização para diferentes ritmos de aprendizagem



Comunicação crítica sem acesso a intérpretes

Disponibilização em tablets/ecrãs interativos em urgências e triagens hospitalares.

Requisitos de fiabilidade muito exigentes:

- Erro de reconhecimento pode ter **consequências graves** (sintomas, alergias)
- Necessidade de **limiar de confiança mínimo** com indicação visual ao utilizador
- Questões de certificação e responsabilidade médica

O sistema **complementa** — não substitui — o trabalho dos intérpretes profissionais.



Acessibilidade universal em espaços públicos

Museus, transportes, câmaras municipais, serviços públicos.

Alinhamento com:

- Diretiva europeia de acessibilidade digital **2016/2102/UE**
- ODS 10 (Redução das Desigualdades) e ODS 11 (Cidades Sustentáveis)

Desafios em ambiente não controlado:

- Iluminação variável, fundos complexos, movimento de terceiros
- Posicionamento físico da câmara
- Implicações de **privacidade (RGPD)** em espaços públicos

5 Dimensões Sociais e Éticas



Participação comunitária

A comunidade surda deve estar envolvida em todas as fases — desde a definição de requisitos até à validação (Glasser et al., 2025)

Não substituição de intérpretes

O sistema é uma ferramenta de apoio, não um substituto para contextos de alta complexidade

Viés nos dados

Dataset recolhido em contexto geográfico restrito pode não generalizar para variantes regionais

A tradução automática no estado atual **não atinge a qualidade** de um intérprete humano certificado em contextos de elevada complexidade (audiências judiciais, negociações).

Privacidade e RGPD



Dados capturados e classificação legal:

- Imagens de vídeo → **dados pessoais**
- Landmarks biométricos extraídos → **dados biométricos** (Artigo 4.º do RGPD)

Processamento local (on-device)

Vídeo processado no dispositivo do utilizador, sem transmissão para servidores externos

Não persistência

Nenhum dado identificador armazenado após o reconhecimento do gesto

Síntese de voz local

Sem APIs externas, sem chaves de acesso

6 Conclusão

Síntese e Trabalho Futuro



Principais contribuições:

- Revisão do estado da arte (IEEE Xplore, Springer, MDPI, arXiv)
- Pipeline arquitetural MediaPipe + MLP/LSTM + LLM local, transferível para LGP
- Análise de cenários de aplicação e dimensões sociais/éticas

Limitações:

- Implementação foca em ASL (não LGP) por falta de datasets públicos
- Segmentação temporal automática de gestos de difícil implementação

Trabalho futuro:

- Recolha e anotação de **datasets de LGP** de maior dimensão
- Reconhecimento de **língua gestual contínua** em cenários reais
- Exploração de **Transformers** e tradução **bidirecional** (texto → avatar 3D com gestos sintetizados)