

Reconhecimento e Tradução de Língua Gestual para Texto e Voz com Recurso a Visão Computacional e Machine Learning

No Author Given

Universidade do Minho, Portugal

Abstract. Este trabalho apresenta uma análise sobre o estado da arte em sistemas de reconhecimento e tradução de língua gestual com recurso a visão computacional e Machine Learning, enquadrando este estudo na motivação de tornar a Língua Gestual Portuguesa (LGP) acessível através da tecnologia. A câmara de vídeo é utilizada como sensor principal para a captura dos gestos e expressões, enquanto a framework MediaPipe extrai landmarks tridimensionais das mãos, cara e corpo em tempo real. São analisadas abordagens para o reconhecimento de gestos estáticos — correspondentes ao alfabeto dactilológico — e de gestos dinâmicos — correspondentes a palavras e frases completas. Dado que a LGP carece de datasets públicos anotados em quantidade suficiente para treinar modelos robustos, a implementação prática desenvolvida neste trabalho recorre à American Sign Language (ASL), que dispõe de recursos de dados amplamente estabelecidos. O sistema proposto visa eliminar barreiras de comunicação entre a comunidade surda e a população ouvinte. O artigo discute ainda cenários de implementação, questões éticas, privacidade de dados e tendências futuras da inteligência artificial aplicadas a este domínio.

Keywords: Língua Gestual Portuguesa · American Sign Language · Reconhecimento de Gestos · MediaPipe · Acessibilidade · Ética em IA.

1 Introdução

A língua gestual é a língua natural da comunidade surda, constituindo um sistema linguístico completo com gramática, sintaxe e semântica próprias. Em Portugal, a Língua Gestual Portuguesa (LGP) é reconhecida constitucionalmente como a língua da comunidade surda portuguesa, sendo utilizada por aproximadamente 30.000 pessoas como língua principal de comunicação [1].

Apesar do seu reconhecimento legal, a LGP continua a ser desconhecida pela grande maioria da população ouvinte, criando uma barreira de comunicação significativa em contextos quotidianos como serviços de saúde, educação, transportes e serviços públicos. A escassez de intérpretes certificados agrava esta situação, tornando necessário o desenvolvimento de soluções tecnológicas que facilitem esta comunicação.

Os avanços recentes em visão computacional e Machine Learning abriram novas possibilidades para o desenvolvimento de sistemas de tradução automática de língua gestual. Em particular, a disponibilização de frameworks como o MediaPipe, que permitem a extração em tempo real de landmarks tridimensionais das mãos, cara e corpo a partir de câmaras de vídeo convencionais, democratizou o acesso a dados de sensorização de elevada qualidade sem necessidade de hardware especializado.

Este trabalho de investigação enquadra-se no tema de Interação Pessoa-Máquina da unidade curricular de Sensorização e Ambiente. A câmara funciona como sensor visual que captura os gestos e expressões, os landmarks extraídos pelo MediaPipe constituem os dados de sensorização, e os modelos de Machine Learning aplicam as técnicas de processamento de informação. A motivação original do projeto centra-se na LGP; contudo, como se discute na Secção 2.2, a indisponibilidade de datasets públicos anotados para LGP em volume suficiente para treino de modelos de aprendizagem conduziu à adoção da American Sign Language (ASL) como língua alvo na fase de implementação.

O artigo está organizado da seguinte forma: a Secção 2 caracteriza a LGP e os desafios específicos do seu reconhecimento automático; a Secção 3 apresenta o estado da arte em técnicas de captura e reconhecimento de gestos; a Secção 4 descreve a proposta de implementação do sistema; a Secção 5 discute cenários de implementação; a Secção 6 analisa as dimensões sociais relevantes; a Secção 7 discute benefícios, limitações e percalços; e a Secção 8 conclui com as principais observações e perspetivas futuras.

2 Língua Gestual Portuguesa: Caracterização e Desafios

2.1 Estrutura Linguística da LGP

A LGP é uma língua visual-gestual onde os signatários utilizam gestos e expressões para comunicarem. A sua estrutura linguística é distinta do Português oral, possuindo gramática própria, incluindo configuração da mão, localização, movimento, orientação da palma e expressão facial como parâmetros fonológicos fundamentais.

Do ponto de vista do reconhecimento automático, distinguem-se dois tipos principais de gestos: gestos estáticos, que correspondem ao alfabeto dactilológico e permitem soletrar palavras letra a letra; e gestos dinâmicos, que envolvem movimento e correspondem a palavras ou expressões lexicais completas. O reconhecimento de gestos dinâmicos é consideravelmente mais complexo, pois requer a análise de sequências temporais.

No que respeita à dimensão lexical, o léxico da LGP é rico e está em constante evolução, como é característico de qualquer língua natural viva. Contudo, a LGP é uma língua com uma comunidade de utilizadores relativamente reduzida [1] — o que se reflete numa menor quantidade de recursos sistematizados quando comparada com línguas gestuais de maior expressão internacional. A ASL (American

Sign Language), utilizada por cerca de meio milhão de pessoas nos EUA [2], dispõe de bases de dados lexicais extensas que catalogam propriedades de milhares de gestos.



Fig. 1. Alfabeto dactitológico português




Fig. 2. Alfabeto dactitológico americano

2.2 Disponibilidade de Dados e Justificação da Escolha da ASL

Um dos principais obstáculos ao desenvolvimento de sistemas de reconhecimento de LGP é a escassez de datasets anotados e de acesso público. Os poucos recursos existentes para LGP são de pequena dimensão e com um número reduzido de signatários, o que limita severamente a capacidade de generalização dos modelos treinados com eles.

Esta limitação tem uma consequência decisiva na implementação deste trabalho. O treino de modelos de aprendizagem profunda robustos para reconhecimento de gestos requer grandes volumes de dados anotados com diversidade de

signatários, condições de iluminação e variantes regionais. Para a LGP, tal volume de dados não se encontra publicamente disponível no momento de realização deste trabalho.

A American Sign Language (ASL), por outro lado, dispõe de múltiplos datasets de referência publicamente acessíveis: o dataset ASL Alphabet [3] contém mais de 87.000 imagens de 29 classes para reconhecimento estático, tendo sido utilizado em muitos estudos publicados. Existem ainda o WLASL (Word-Level American Sign Language) [4] com mais de 2.000 sinais distintos, o ASL-LEX [5] com propriedades lexicais de cerca de 3.000 gestos, entre outros. Esta disponibilidade de recursos é consequência do número de utilizadores de ASL e do ecossistema de investigação académica desenvolvido ao longo de décadas nos principais centros universitários norte-americanos.

Assim, por razões de viabilidade técnica e científica, a implementação prática desenvolvida neste trabalho foca-se na ASL, utilizando os datasets públicos disponíveis. Esta escolha não invalida a pertinência social do trabalho no contexto português: as metodologias desenvolvidas e validadas para ASL — extração de landmarks, treino de classificadores, pipeline de inferência em tempo real — são transferíveis para LGP logo que datasets adequados estejam disponíveis, quer através de iniciativas de recolha de dados comunitárias, quer através de futuras colaborações com a comunidade surda portuguesa.

3 Estado da Arte

3.1 Técnicas de Captura e Sensorização

As abordagens para captura de gestos podem ser divididas em dois grandes grupos: baseadas em hardware especializado e baseadas em visão computacional. As primeiras incluem luvas com sensores de flexão e acelerómetros, que fornecem dados precisos mas são intrusivas, dispendiosas e limitam a naturalidade do gesto. As segundas recorrem a câmaras de vídeo convencionais, tornando o sistema acessível e não-invasivo.

Dentro das abordagens por visão computacional, é possível distinguir entre sistemas que trabalham diretamente com imagens (pixels) e sistemas que extraem representações intermédias como esqueletos ou landmarks. A extração de landmarks tridimensionais da mão apresenta vantagens significativas: reduz a dimensionalidade dos dados, é invariante a mudanças de iluminação e cor de pele, e facilita a interpretação do modelo.

3.2 MediaPipe - Framework de Sensorização

O MediaPipe Hands [6], desenvolvido pelo Google, é uma framework open-source que permite a deteção e rastreamento em tempo real de até duas mãos a partir de uma câmara RGB convencional. Para cada mão detetada, extrai 21 landmarks tridimensionais correspondentes às articulações dos dedos e da palma, formando um vector de 63 valores (21 pontos $\times$ 3 coordenadas x, y, z). A inferência é

executada localmente no dispositivo (on-device), sem necessidade de envio de dados para servidores externos.

Para gestos dinâmicos que envolvam o corpo e a face, o MediaPipe Holistic [7] combina a detecção de pose corporal (33 landmarks), malha facial (468 pontos) e landmarks de ambas as mãos numa única pipeline, fornecendo uma representação completa do signatário em tempo real.




Fig. 3. Landmarks detetados pelo MediaPipe

3.3 Modelos de Machine Learning para Reconhecimento de Gestos

Gestos Estáticos - Alfabeto Dactilográfico

O reconhecimento de gestos estáticos corresponde a um problema de classificação multiclasse onde, a partir dos landmarks de uma única frame, se determina a letra do alfabeto representada. As abordagens mais comuns incluem redes neurais densas (MLP), redes convolucionais (CNN) e algoritmos clássicos como SVM e Random Forest.

Pugeault e Bowden [13] apresentaram um dos primeiros sistemas de referência para reconhecimento do alfabeto ASL em tempo real, utilizando classificadores de Random Forest sobre características de aparência da mão, obtendo cerca de 57% de *accuracy* num cenário sem segmentação prévia. Este resultado ilustra

a dificuldade do problema em condições não controladas quando são utilizadas representações baseadas diretamente em pixels. A adoção de landmarks tridimensionais como representação de entrada altera substancialmente este cenário: Buttar *et al.* [9] reportam aproximadamente 92% de *accuracy* utilizando redes neurais profundas sobre landmarks de mãos, enquanto vários trabalhos na literatura reportam valores superiores a 95% em condições de laboratório controladas [3]. Esta diferença justifica a escolha de landmarks como representação de entrada na implementação proposta, em detrimento de abordagens baseadas diretamente em pixels.

Gestos Dinâmicos

O reconhecimento de gestos dinâmicos requer a análise de sequências temporais de landmarks, tornando as arquiteturas recorrentes as mais adequadas. As redes LSTM (Long Short-Term Memory) e GRU (Gated Recurrent Units) são as mais utilizadas, sendo capazes de capturar dependências temporais em sequências de comprimento variável.

Srivastava *et al.* [8] demonstraram a eficácia de um sistema baseado em MediaPipe Holistic combinado com LSTM para reconhecimento contínuo de língua gestual, obtendo resultados superiores a abordagens baseadas diretamente em imagens RGB para a maioria das classes gestuais (88% accuracy). Buttar *et al.* [9] propuseram uma abordagem híbrida CNN+LSTM que combina características espaciais (extração por CNN) com análise temporal (LSTM), obtendo accuracy de 92%.

A Tabela 1 sintetiza um conjunto de trabalhos representativos do estado da arte, evidenciando as diferenças ao nível dos dados, das arquiteturas e do desempenho reportado.

Table 1. Comparação de sistemas representativos de reconhecimento de língua gestual.

Trabalho	Dataset	Modelo	Acc. (%)	Tipo de gesto
Srivastava et al. [8]	Dataset próprio	MediaPipe Holistic + LSTM	88	Dinâmico (frases)
Buttar et al. [9]	ASL Alphabet	CNN + LSTM	92	Estático + Dinâmico
Vários (literatura)	ASL Alphabet	CNN	>95	Estático (alfabeto)

3.4 Sistemas Existentes para ASL e LGP

A literatura regista uma assimetria marcante entre sistemas desenvolvidos para ASL e os desenvolvidos para LGP ou outras línguas gestuais europeias. Esta assimetria manifesta-se tanto na quantidade de publicações como nos níveis de desempenho reportados, condicionados em grande medida pela disponibilidade de dados de treino.

Para a ASL, os sistemas existentes dividem-se em dois grupos funcionais com níveis de maturidade distintos. O primeiro grupo cobre o reconhecimento do alfabeto dactilológico (*fingerspelling*): trata-se de um problema de classificação estática com 26–29 classes bem separadas, e a literatura regista *accuracies* superiores a 95% em condições controladas [3]. O segundo grupo cobre o reconhecimento de sinais completos (*word-level* e *sentence-level*), consideravelmente mais difícil: sistemas baseados no WLASL reportam tipicamente *accuracies* entre 60% e 80% para os sinais mais frequentes, com degradação significativa em condições não controladas. Esta diferença não é surpreendente dado que o reconhecimento word-level implica distinguir centenas de padrões temporais com variabilidade inter-signatário relevante.

Para línguas gestuais europeias próximas da LGP, como a Língua Gestual Espanhola (LSE) e a Língua Gestual Francesa (LSF), existem alguns datasets e sistemas publicados, mas o volume de investigação é substancialmente inferior ao da ASL. Para a LGP especificamente, não são conhecidos, no momento de realização deste trabalho, sistemas de reconhecimento automático apoiados em datasets de grande dimensão publicamente acessíveis. Esta disparidade reforça a pertinência do desenvolvimento de metodologias e infraestruturas de dados para LGP, e justifica a opção de validar as técnicas propostas num contexto com dados abundantes (ASL) antes de as transferir para a LGP.

4 Proposta de Implementação

Esta secção descreve a arquitetura e as decisões técnicas que guiarão a implementação prática desenvolvida na segunda fase deste trabalho. O sistema é composto por dois módulos de reconhecimento complementares — gestos estáticos e gestos dinâmicos — partilhando o mesmo sensor e pipeline de sensorização, e convergindo num módulo de output de texto e voz.

4.1 Arquitetura Geral do Sistema

O pipeline completo do sistema proposto pode ser descrito nas seguintes etapas sequenciais:

1. Captura: câmara RGB convencional captura vídeo em tempo real;
2. Sensorização: MediaPipe extrai landmarks tridimensionais frame a frame;
3. Classificação: módulo estático (MLP) ou dinâmico (LSTM) reconhece o gesto;
4. Pós-processamento: um LLM recebe a sequência de palavras reconhecidas e gera uma frase gramaticalmente coerente;
5. Output: a frase é apresentada em texto e sintetizada em voz.

A interface com o utilizador será implementada como uma aplicação web local, acessível através de qualquer browser sem necessidade de instalação adicional. Esta escolha justifica-se pela sua integração nativa com componentes de webcam, texto e áudio, e pela compatibilidade com os restantes componentes do sistema.

4.2 Módulo de Gestos Estáticos — Alfabeto Dactilológico

O primeiro módulo, e núcleo central da implementação, destina-se ao reconhecimento do alfabeto dactilológico da ASL, correspondendo a um problema de classificação multiclasse com 29 classes (26 letras e 3 gestos especiais: *space*, *delete* e *nothing*).

Dataset

Será utilizado o *ASL Alphabet Dataset* disponível no Kaggle [3], composto por mais de 87.000 imagens de treino distribuídas uniformemente pelas 29 classes, recolhidas em condições controladas de iluminação e fundo.

Pipeline de treino

Cada imagem será processada pelo MediaPipe Hands, extraíndo 21 landmarks tridimensionais da mão, resultando num vetor de 63 valores numéricos (21 pontos $\times$ 3 coordenadas x, y, z) que constitui o input do modelo. Esta abordagem é preferível ao treino direto sobre pixels por três razões: reduz drasticamente a dimensionalidade do input, é invariante a diferenças de iluminação e cor de pele, e requer significativamente menos recursos computacionais.

O modelo proposto é um Multi Layer Perceptron (MLP) com duas a três camadas densas. A literatura reporta accuracies bastante altas para este tipo de arquitectura com input de landmarks em condições comparáveis [9].

4.3 Módulo de Gestos Dinâmicos — Palavras e Frases

O segundo módulo, previsto como extensão da implementação base, destina-se ao reconhecimento de sinais correspondentes a palavras completas, envolvendo a análise de sequências temporais de landmarks.

Dataset

Será utilizado um subconjunto do *Word-Level American Sign Language (WLASL)* dataset [4], especificamente o WLASL-100, composto pelos 100 gestos mais frequentes. Esta limitação de scope é intencional: o WLASL completo contém mais de 2.000 sinais, o que implicaria um tempo de treino do modelo demasiado extenso tendo em conta os recursos disponíveis nesta etapa inicial.

Pipeline de treino

Cada vídeo será processado pelo MediaPipe Holistic, extraíndo landmarks das mãos, pose corporal e face em simultâneo. Uma vez que os gestos envolvem sequências temporais, o modelo adequado é uma rede recorrente — LSTM (*Long Short-Term Memory*) —, capaz de capturar dependências temporais, tal como demonstrado na literatura para reconhecimento contínuo de língua gestual [8].

Um desafio específico deste módulo é a qualidade variável dos vídeos do WLASL, recolhidos em condições não controladas, o que pode originar falhas na

deteção de landmarks pelo MediaPipe. A estratégia de mitigação poderá ser a interpolação linear dos landmarks em frames onde a deteção falhe, descartando vídeos com mais de X% de frames sem deteção válida.

Pós-processamento com LLM

A gramática da ASL difere estruturalmente do inglês, pelo que a sequência de sinais reconhecidos pelo LSTM não corresponde diretamente a uma frase gramaticalmente correta. Para resolver este problema, a sequência de palavras reconhecidas será enviada como prompt a um *Large Language Model* (LLM) com a instrução de gerar uma frase natural e coerente em inglês. Esta abordagem permite, por exemplo, converter a sequência ["I", "WANT", "WATER"] numa frase como *"I would like some water, please."*

4.4 Síntese de Voz

O output textual gerado será sintetizado em voz através de uma biblioteca que opere localmente no dispositivo sem necessidade de conectividade de rede nem chaves de API externas. Esta escolha é consistente com o princípio de *privacy by design* discutido na Secção 5.2, uma vez que nenhum dado é transmitido para servidores externos durante a síntese.

4.5 Alternância entre Modos e Limitações de Segmentação

Na implementação proposta, os dois módulos de reconhecimento operam em modos distintos que requerem alternância manual por parte do utilizador. No modo estático, o sistema classifica continuamente frame a frame, acumulando letras numa palavra. No modo dinâmico, o utilizador acciona um botão, executa o sinal durante aproximadamente um a dois segundos, e o sistema classifica a sequência de frames resultante como uma palavra do vocabulário WLASL-100. Esta separação é uma consequência direta das diferenças arquitecturais dos dois modelos: o MLP analisa uma única frame enquanto o LSTM requer uma sequência de comprimento fixo, tornando impossível a execução simultânea e transparente dos dois modelos sobre o mesmo stream de vídeo.

A eliminação desta necessidade de alternância manual implicaria resolver o problema de segmentação temporal automática de gestos — detectar automaticamente quando um gesto começa e termina, e decidir em tempo real se é estático ou dinâmico. Esta é uma área de investigação ativa e de considerável complexidade, estando fora do âmbito desta fase do trabalho. A alternância manual é assim reconhecida como uma limitação do sistema actual, e a implementação de segmentação temporal automática é identificada como uma extensão prioritária para trabalho futuro.

4.6 Síntese da Proposta

A Tabela 2 resume as decisões técnicas de cada módulo.

Table 2. Resumo das decisões técnicas da implementação proposta.

Componente	Gestos Estáticos	Gestos Dinâmicos
Dataset	ASL Alphabet (Kaggle)	WLASL-100
Sensorização	MediaPipe Hands	MediaPipe Holistic
Modelo	MLP	LSTM
Classes	29 (alfabeto ASL)	100 palavras

5 Cenários de Implementação e Desenvolvimento

5.1 Contexto Educativo e Gamificação

O primeiro cenário de implementação visa o contexto educativo, nomeadamente aplicações para o ensino e aprendizagem da LGP por parte de pessoas ouvintes. O sistema pode ser utilizado como ferramenta de prática interativa onde o utilizador executa gestos e recebe feedback imediato sobre a correção da execução.

A integração de elementos de ludificação (gamification) — como pontuações, níveis de dificuldade progressivos, conquistas e tabelas de classificação — pode aumentar significativamente o envolvimento e a persistência dos utilizadores. Este modelo é análogo ao adotado por aplicações de aprendizagem de línguas orais como o Duolingo [10], adaptado à modalidade gestual.

Esta ideia pode ainda ser adaptada para cenários de sala de aula, com o professor a ter acesso a uma *dashboard* com o progresso dos seus alunos. Contudo, este cenário coloca desafios próprios: a variabilidade de hardware disponível em contexto escolar (qualidade das webcams, iluminação das salas) pode degradar a fiabilidade da deteção de landmarks; a adaptação do feedback a diferentes ritmos e estilos de aprendizagem exige uma componente de personalização que vai além do sistema de reconhecimento base.

5.2 Contexto de Saúde e Serviços de Emergência

O segundo cenário de implementação foca-se em contextos onde a comunicação é crítica mas o acesso a intérpretes é limitado ou impossível. Em ambiente hospitalar, a incapacidade de comunicação entre profissionais de saúde e doentes surdos pode comprometer a qualidade dos cuidados prestados e, em situações de emergência, colocar vidas em risco.

O sistema poderia ser disponibilizado em tablets ou ecrãs interativos em serviços de urgência, triagem e consultas, permitindo ao doente surdo comunicar através de LGP e receber a tradução em tempo real. A solução complementar — sem pretender substituir — o trabalho dos intérpretes profissionais em situações de maior complexidade.

No entanto, este é o cenário que impõe os requisitos de fiabilidade mais exigentes. Um erro de reconhecimento num contexto clínico pode ter consequências graves: a confusão entre sinais semelhantes pode resultar na comunicação errada de sintomas ou alergias. Por esta razão, seria necessário estabelecer um limiar de confiança mínimo para as predições do modelo, com recurso a uma indicação

visual clara ao utilizador quando o sistema tem baixa confiança no reconhecimento. A integração em workflows médicos existentes levantaria ainda questões de certificação e responsabilidade que excedem o âmbito atual do trabalho.

5.3 Cidades Inteligentes e Espaços Públicos

O terceiro cenário enquadra-se na visão das Cidades Inteligentes e na promoção da acessibilidade universal em espaços públicos. O sistema poderia ser integrado em zonas de informação em museus, transportes, câmaras municipais e serviços públicos, permitindo a utilizadores surdos interagir com estes sistemas de forma autónoma através da sua língua natural.

Neste contexto, o sistema funciona como uma camada de acessibilidade que democratiza o acesso a serviços digitais para a comunidade surda, alinhando-se com as diretrizes europeias de acessibilidade digital (Diretiva 2016/2102/UE) e com os objetivos de Desenvolvimento Sustentável da ONU, nomeadamente o ODS 10 (Redução das Desigualdades) e o ODS 11 (Cidades e Comunidades Sustentáveis).

Tratando-se de espaços não controlados, este cenário expõe o sistema a condições adversas particularmente desafiantes: iluminação variável (luz solar direta, espaços com baixa luminosidade), fundos complexos e movimento de pessoas no campo de visão da câmara podem degradar significativamente o desempenho do MediaPipe. Adicionalmente, o posicionamento físico do sistema — distância e *ângulo* da câmara relativamente ao utilizador — tem impacto direto na qualidade da deteção. A instalação em espaços públicos requer ainda uma análise cuidada das implicações de privacidade, uma vez que a câmara pode capturar imagens de terceiros não participantes, o que é particularmente sensível ao abrigo do RGPD em contextos de uso continuado.

6 Dimensões Sociais

6.1 Questões Éticas

O desenvolvimento de sistemas de tradução automática de língua gestual levanta questões éticas que devem ser consideradas desde as fases iniciais do projeto. A primeira e mais fundamental é a de saber se a tecnologia serve verdadeiramente os interesses da comunidade surda ou se, pelo contrário, impõe uma solução desenvolvida externamente sem consulta às pessoas que mais a utilizarão.

Glasser *et al.* [11] argumentam que o desenvolvimento ético de IA para língua gestual requer a participação ativa da comunidade surda em todas as fases — desde a definição dos requisitos até à validação dos resultados — e não apenas como utilizadores finais. O envolvimento de signatários nativos na recolha de dados, anotação e teste do sistema é essencial para garantir que o sistema aprende representações autênticas da LGP e não versões simplificadas ou artificiais.

Outro risco ético relevante é o da substituição de intérpretes humanos. É fundamental que o sistema seja posicionado como ferramenta de apoio e complemento ao trabalho dos intérpretes, e não como substituto. A tradução automática

de língua gestual no estado atual da tecnologia não atinge a qualidade, nuance e fiabilidade contextual de um intérprete humano certificado, especialmente em contextos de alta complexidade como audiências judiciais ou negociações.

Um risco adicional a considerar é o do viés nos dados de treino: se o dataset for recolhido com participantes de uma região geográfica específica ou faixa etária restrita, o modelo poderá ter dificuldade em generalizar para variantes regionais da LGP ou para signatários mais idosos.

6.2 Privacidade de Dados

O sistema recorre a câmara de vídeo para capturar imagens do utilizador em tempo real, o que levanta questões relevantes ao abrigo do Regulamento Geral sobre a Proteção de Dados (RGPD). As imagens de vídeo constituem dados pessoais, e os landmarks biométricos extraídos pelo MediaPipe podem, em princípio, ser utilizados para identificação de indivíduos, classificando-se como dados biométricos na aceção do artigo 4.^o do RGPD.

A abordagem mais adequada para mitigar estes riscos é o processamento local (*on-device*): as imagens de vídeo são processadas diretamente no dispositivo do utilizador, sem que dados visuais sejam transmitidos para servidores externos. Apenas os landmarks (coordenadas numéricas dos pontos-chave da mão) são processados pelo modelo de classificação, e nenhum dado identificativo é armazenado após o reconhecimento do gesto.

Em todos os contextos onde o sistema seja disponibilizado, é necessário garantir: (1) informação clara ao utilizador sobre os dados recolhidos e processados; (2) não persistência de dados pessoais após a sessão.

6.3 Tendências Futuras da Inteligência Artificial

O campo do reconhecimento de língua gestual tem beneficiado dos avanços gerais em aprendizagem profunda e, mais recentemente, de arquiteturas baseadas em Transformers. O SignBERT [12] é um exemplo de modelo de linguagem pré-treinado especificamente para língua gestual, análogo ao BERT para linguagem natural, capaz de aprender representações ricas de gestos através de pré-treino auto-supervisionado em grandes volumes de dados não anotados.

A integração com modelos de linguagem de grande dimensão (LLMs) abre perspetivas para a tradução de língua gestual contínua para texto natural com correção gramatical e contextual, superando as limitações dos modelos de reconhecimento de gestos isolados que não capturam a gramática específica da LGP.

Uma tendência particularmente relevante é a da tradução bidirecional: enquanto o sistema proposto traduz ASL para texto/voz (reconhecimento), a direção inversa — texto/voz para ASL — pode ser abordada através de avatares tridimensionais animados que reproduzem gestos sintetizados, permitindo uma comunicação verdadeiramente bidirecional entre surdos e ouvintes sem necessidade de intérprete.

A sensorização móvel constitui outra tendência relevante: a crescente capacidade de processamento dos dispositivos móveis permite a execução de modelos de reconhecimento de gestos diretamente em smartphones, tornando o sistema acessível em qualquer contexto sem necessidade de infraestrutura dedicada.

7 Análise de Benefícios, Limitações e Percalços

7.1 Benefícios

O principal benefício do sistema proposto é a promoção da inclusão social da comunidade surda através da eliminação ou redução das barreiras de comunicação em contextos onde o acesso a intérpretes é limitado. Do ponto de vista técnico, a utilização da câmara como sensor e do MediaPipe como middleware de sensorização permite um sistema de baixo custo, não-invasivo e executável em hardware de consumo corrente.

A natureza local do processamento (*on-device*) constitui simultaneamente um benefício de privacidade e de robustez: o sistema funciona sem conectividade de rede e sem dependência de serviços externos, tornando-o adequado para contextos com conectividade limitada.

7.2 Limitações, Percalços e Análise da Qualidade dos Dados

A principal limitação deste trabalho é a impossibilidade de implementar diretamente um sistema para LGP, devido à escassez de datasets públicos anotados em quantidade suficiente para treinar modelos de aprendizagem profunda. Por esta razão, a implementação prática recorre à ASL, que dispõe de recursos de dados amplamente utilizados na literatura, conforme discutido na Secção 2.2. Embora metodologicamente válida, esta escolha implica que os resultados obtidos não são diretamente transferíveis para LGP sem uma futura etapa de recolha de dados e adaptação dos modelos.

Qualidade e Viés dos Datasets Utilizados

O *ASL Alphabet Dataset* foi recolhido em condições relativamente controladas, com fundo uniforme e iluminação constante. Em sistemas baseados diretamente em imagens RGB, esta homogeneidade pode limitar a capacidade de generalização para cenários reais. No entanto, na abordagem proposta neste trabalho as imagens são primeiro processadas pelo *MediaPipe Hands*, que extrai landmarks tridimensionais da mão utilizados como input do classificador. Esta representação geométrica reduz significativamente a dependência de fatores visuais como iluminação ou fundo. Adicionalmente, a diversidade limitada de signatários no dataset pode não capturar completamente a variabilidade anatômica e estilística presente na população real.

O *WLASL dataset* apresenta limitações distintas. Os vídeos foram recolhidos a partir de fontes heterogêneas, resultando em grande variabilidade de qualidade, resolução e ângulos de câmara. Em alguns casos verificam-se oclusões ou

movimentos rápidos que dificultam a detecção de landmarks. Para mitigar este problema, podem ser aplicadas estratégias de pré-processamento, como a interpolação de pontos em frames com detecção falhada ou o descarte de amostras, descritas na Secção 4.3. Adicionalmente, a distribuição de frequência dos sinais no dataset é desequilibrada, podendo introduzir viés de classe durante o treino dos modelos.

Questões de Consentimento e Uso Ético dos Dados

A utilização de datasets públicos levanta também questões relativas ao consentimento informado e ao uso ético dos dados. No caso do WLASL, parte dos vídeos provém de conteúdos online disponíveis publicamente, nem sempre sendo claro se os participantes autorizaram explicitamente a reutilização dos seus dados para fins de investigação.

Adicionalmente, é importante considerar o impacto social de sistemas automáticos de tradução de língua gestual. Estas tecnologias devem ser entendidas como ferramentas de apoio à acessibilidade, complementando — e não substituindo — o trabalho de intérpretes humanos e outras políticas de inclusão da comunidade surda.

8 Conclusão

Este artigo apresentou uma análise do estado da arte em sistemas de reconhecimento e tradução de língua gestual para texto e voz com recurso a visão computacional e técnicas de Machine Learning. O trabalho foi motivado pela necessidade de desenvolver soluções tecnológicas acessíveis que possam contribuir para reduzir barreiras de comunicação entre a comunidade surda e a população ouvinte.

A análise da literatura permitiu identificar o MediaPipe como uma framework de sensorização particularmente adequada para este domínio, permitindo a extração em tempo real de landmarks tridimensionais das mãos, face e corpo a partir de câmaras RGB convencionais. No que respeita às técnicas de reconhecimento, observou-se que abordagens baseadas em redes neuronais — como MLP, CNN e LSTM — apresentam desempenhos elevados em tarefas de classificação de gestos estáticos e dinâmicos quando treinadas com datasets adequados.

Uma das principais limitações identificadas é a escassez de datasets anotados de LGP, o que constitui atualmente um obstáculo significativo ao desenvolvimento de sistemas robustos para esta língua. Por esta razão, a implementação prática proposta neste trabalho recorre à ASL, que dispõe de datasets amplamente utilizados na literatura e que permitem validar as arquiteturas e metodologias propostas.

Apesar desta limitação, as técnicas desenvolvidas neste trabalho — nomeadamente a utilização de landmarks extraídos pelo MediaPipe como representação intermédia para modelos de classificação — constituem uma base metodológica que poderá ser aplicada a outras línguas gestuais. Embora a implementação atual se concentre na ASL devido à disponibilidade de dados públicos, o pipeline

arquitetural proposto é largamente independente da língua gestual específica e pode ser adaptado à LGP assim que datasets adequados estejam disponíveis.

Adicionalmente, a análise das dimensões sociais e éticas associadas ao desenvolvimento deste tipo de tecnologia sublinha a importância de envolver a comunidade surda no processo de criação e validação destes sistemas. A participação ativa de signatários nativos é essencial para garantir que as soluções desenvolvidas refletem de forma fiel a diversidade e complexidade das línguas gestuais.

Como trabalho futuro, destaca-se a necessidade de recolha e anotação de datasets de LGP de maior dimensão e diversidade, bem como o desenvolvimento de modelos capazes de reconhecer língua gestual contínua em cenários do mundo real. Em particular, a investigação futura poderá explorar técnicas de segmentação automática de gestos e arquiteturas mais avançadas baseadas em modelos sequenciais ou Transformers, aproximando estes sistemas de aplicações práticas em contextos educativos, serviços públicos e ambientes clínicos.

References

1. XXIII Governo da República Portuguesa: Mãos que falam: hoje é Dia Nacional da Língua Gestual Portuguesa. Notícia oficial (2023). <https://www.portugal.gov.pt/pt/gc23/comunicacao/noticia?i=maos-que-falam-hoje-e-dia-nacional-da-lingua-gestual-portuguesa>
2. ASL Bloom Team: How Many People Use ASL? ASL Bloom Blog (2025). <https://www.aslbloom.com/blog/how-many-people-use-asl>
3. Grassknoted: ASL Alphabet Dataset. Kaggle (2018). <https://www.kaggle.com/datasets/grassknoted/asl-alphabet>
4. Li, D., et al.: Word-Level Deep Sign Language Recognition from Video: A New Large-Scale Dataset and Methods Comparison. In: Proc. WACV (2020). <https://dxli94.github.io/WLASL/>
5. Sehyr, Z.S., et al.: ASL-LEX 2.0: A Multidimensional Database of American Sign Language. GitHub Repository (2021). <https://github.com/ASL-LEX/asl-lex>
6. MediaPipe: Hands Solution. Google MediaPipe Documentation. <https://mediapipe.readthedocs.io/en/latest/solutions/hands.html>
7. Google Research: MediaPipe Holistic — Simultaneous Face, Hand and Pose Prediction, On-device. Google Research Blog (2020). <https://research.google/blog/mediapipe-holistic-simultaneous-face-hand-and-pose-prediction-on-device/>
8. Srivastava, S., Singh, S., Pooja, Prakash, S.: Continuous Sign Language Recognition System Using Deep Learning with MediaPipe Holistic. *Wireless Pers. Commun.* **137**(3), 1455–1468 (2024). <https://doi.org/10.1007/s11277-024-11356-0> <https://arxiv.org/abs/2411.04517>
9. Buttar, A.M., et al.: Deep Learning in Sign Language Recognition: A Hybrid Approach for the Recognition of Static and Dynamic Signs. *Mathematics* **11**(17), 3729 (2023). <https://doi.org/10.3390/math11173729>
10. Duolingo Inc.: Duolingo – Language Learning Platform (2025). <https://www.duolingo.com>
11. Glasser, A., Kushalnagar, R., Vogler, C.: Inclusive Sign Language AI: Towards Authentic Accessibility Through Community Collaboration. In: Proc. ICCV Workshop on Multimodal Sign Language Recognition (MSLR) (2025).

- https://openaccess.thecvf.com/content/ICCV2025W/MSLR/papers/Glasser_Inclusive_Sign_Language_AI_Towards_Authentic_Accessibility_Through_Community_Collaboration_ICCVW_2025_paper.pdf
12. Hu, H., Zhao, W., Zhou, W., Li, H.: SignBERT+: Hand-model-aware Self-supervised Pre-training for Sign Language Understanding. *IEEE Trans. Pattern Anal. Mach. Intell.* **45**, 1–20 (2023). <https://doi.org/10.1109/TPAMI.2023.3267897>
<https://signbert-zoo.github.io/>
 13. Pugeault, N., Bowden, R.: Spelling It Out: Real-Time ASL Finger-spelling Recognition. In: *Proc. IEEE ICCV Workshops*, pp. 1033–1039 (2011). <https://doi.org/10.1109/ICCVW.2011.6130290>